Trabajo Practico N° 3
Minería de datos

Objetivo

El objetivo de este trabajo práctico es integrar los conocimientos adquiridos en las unidades 5 y 6 en un problema real de **clasificación multiclase**, asociado a la recomendación de cultivos agrícolas en función de parámetros de suelo y clima. La variable objetivo es *Clase* (tipo de cultivo recomendado, con 10 clases).

Descripción del conjunto de datos

El conjunto de datos *crop_recommendation_geo.csv*[1] contiene **50005 muestras** y **17 columnas**. Las 16 variables predictoras son:

Variable	Descripción
N	Nitrógeno total en el suelo (0-30 cm)
P	Fósforo disponible para las plantas (Olsen)
exch_bases	Bases intercambiables totales (Ca + Mg + K + Na), capa superficial del suelo: la medición de potasio
ph	pH del suelo en agua (0-30 cm)
soc	Carbono orgánico del suelo (0-30 cm)
arcilla	Fracción arcillosa (0-30 cm)
arena	Fracción de arena (0-30 cm)
cec	Capacidad de intercambio catiónico
temperatura	Temperatura media anual del aire
temp_mim_mensual	Temperatura media del mes más frío
temp_max_mensual	Temperatura media del mes más cálido
humedad	Humedad relativa media anual
lluvia	Precipitación anual
estacionalidad_lluvias	Coeficiente de variación de la precipitación mensual (BIO15)
radiacion_solar	Radiación solar incidente media anual
elevacion	Altura sobre el nivel del mar
Clase	Cultivo recomendado (variable objetivo)

La variable objetivo *Clase* tiene 10 clases: Algodón, Arroz, Banana, Cafe, Coco, Garbanzo, Frijol, Lenteja, Maíz, Manzana

Importante: El conjunto de datos ha sido modificado intencionalmente.

[1]Conjunto de datos original: https://www.kaggle.com/datasets/markjehan/global-crop-recommendation (modificado para este TP)

Trabajo Practico N° 3
Minería de datos

Actividades

1. **Preparación de datos.** Realizar un análisis exploratorio de datos (EDA) sobre el conjunto de datos *crop_recommendation_geo.csv*: visualizar distribuciones de cada variable predictora, analizar correlaciones, verificar la distribución de clases de la variable *Clase*. Detectar y reportar: (a) los valores faltantes, indicando en qué columnas se encuentran y qué estrategia se utiliza para tratarlos (eliminación, imputación por media/mediana, etc.), justificando la decisión; (b) los registros duplicados, indicando cuántos son y qué se hace con ellos; (c) posibles outliers. **Estandarizar las características numéricas** (*StandardScaler*), ya que SVM es sensible a la escala de las variables. Codificar la variable objetivo si corresponde (*LabelEncoder*). Utilizar *random_state=13* en todas las operaciones que lo requieran.
2. **SVM con kernel lineal.** Realizar la predicción de la variable *Clase* utilizando *SVC (kernel='linear')*. Explorar el parámetro de regularización *C*, probando al menos 5 valores en escala logarítmica (por ejemplo: 0.01, 0.1, 1, 10, 100). Para cada valor de *C*, evaluar el rendimiento mediante **validación cruzada estratificada con k=5** (*StratifiedKFold*) sobre todo el conjunto de datos limpio. Reportar para cada configuración: Precisión (Precision weighted), Exhaustividad (Recall weighted) y Exactitud (Accuracy), indicando la media y la desviación estándar obtenida en los 5 folds. Se utiliza el promedio weighted dado que el conjunto de datos presenta un leve desbalance entre clases. Seleccionar la mejor configuración y justificar la elección.
3. **SVM con kernel gaussiano (RBF).** Realizar la predicción de la variable *Clase* utilizando *SVC (kernel='rbf')*. Explorar los parámetros de regularización *C* y ancho del kernel *gamma*, probando al menos 4 valores para cada uno en escala logarítmica (por ejemplo: C = {0.1, 1, 10, 100}, gamma = {0.001, 0.01, 0.1, 1}). Para cada combinación, evaluar el rendimiento mediante **validación cruzada estratificada con k=5**. Reportar: Precisión (Precision weighted), Exhaustividad (Recall weighted) y Exactitud (Accuracy), indicando media y desviación estándar. Presentar los resultados en formato de tabla o heatmap para visualizar la interacción entre *C* y *gamma*. Seleccionar la mejor configuración y justificar.
4. **Random Forest.** Realizar la predicción de la variable *Clase* utilizando *RandomForestClassifier*. Explorar los parámetros: cantidad de estimadores (*n_estimators*: probar al menos 4 valores, por ejemplo 50, 100, 200, 500) y máxima profundidad de los árboles (*max_depth*: probar al menos 4 valores, por ejemplo 5, 10, 20, None). Para cada combinación, evaluar el rendimiento mediante **validación cruzada estratificada con k=5**. Reportar: Precisión (Precision weighted), Exhaustividad (Recall weighted) y Exactitud (Accuracy), indicando media y desviación estándar. Analizar la importancia de las variables (*feature_importances_*) del mejor modelo obtenido. Seleccionar la mejor configuración y justificar.
5. **Comparación de modelos.** Realizar una tabla comparativa de los tres modelos (SVM lineal, SVM RBF y Random Forest) con las métricas obtenidas por la mejor

configuración de cada algoritmo. Incluir la **matriz de confusión** del mejor modelo de cada algoritmo (puede generarse utilizando uno de los folds de la validación cruzada o mediante un split adicional 80/20 con *random_state=13*). Seleccionar y justificar cuál es el modelo más adecuado para este problema, considerando las métricas, la estabilidad entre folds (desviación estándar), la interpretabilidad y el tiempo de entrenamiento.

Nota: *la validación cruzada estratificada con k=5 implica que el conjunto de datos completo (una vez limpio) se divide en 5 particiones (folds) manteniendo la proporción de clases en cada una. Cada fold actúa como conjunto de test una vez, mientras los otros 4 se usan para entrenamiento. Las métricas se reportan como la media ± desviación estándar de los 5 folds. La exploración de hiperparámetros debe realizarse dentro de este esquema (por ejemplo, usando* ***cross_val_score*** *o* ***GridSearchCV*** *con el mismo* ***StratifiedKFold****).*

Presentación

La entrega es por grupos de dos estudiantes y se entrega un archivo por grupo.

Cualquier integrante del grupo puede hacer la entrega mediante el campus de la materia.

El informe deberá tener una cabecera en la que se indique: año, materia, integrantes. Además, deberá contar con una sección de conclusiones al final del mismo.

El formato del informe deberá ser **.ipynb** (Jupyter Notebook) y no debe contener las definiciones teóricas ni el significado de los parámetros de los métodos dados en clase.

Utilizar *random_state=13* en todos los modelos, particiones y validaciones cruzadas para garantizar la reproducibilidad.

Las gráficas mostradas en el informe deben contener una explicación de lo observado y si es coherente con la hipótesis previa. La cantidad de gráficas debe ser acotada (no más de 3-4 por actividad) y representativa.

Las entregas fuera del plazo establecido no serán consideradas salvo excepciones previamente justificadas por el grupo.

Comentario Final: se valorará especialmente la detección y tratamiento correcto de los problemas del conjunto de datos (valores faltantes, duplicados), la correcta interpretación de los resultados, la justificación de las decisiones tomadas y la calidad de las visualizaciones.